

TEKNİK RAPOR

Proje Kodu: Edge-AI-16

Proje Adı: Yapay Zeka ve Uzaktan Algılama Tabanlı Hibrit Orman Yangını Erken Uyarı ve Karar Destek Platformu

Geliştirici: Serdar ÖNAL (Kıdemli İnşaat Mühendisi & Yapay Zeka Araştırmacısı)

Tarih: 18 Mayıs 2026

1. YÖNETİCİ ÖZETİ (EXECUTIVE SUMMARY)

Bu çalışma; küresel iklim kriziyle birlikte artan orman yangınlarına karşı, yapay zeka (Deep Learning) ve coğrafi bilgi sistemlerini (GIS) bir araya getiren hibrit bir erken uyarı prototipidir. Projenin temel hedefi; dron, uydu veya sınır bilişim (Edge AI) cihazlarında çalışabilecek ultra hafif, enerji tasarruflu ve yüksek doğruluklu bir görüntü sınıflandırma beyni geliştirmek, bu beyni canlı NASA FIRMS uydu verileriyle besleyerek yerelleştirilmiş anlık bir takip paneline dönüştürmektir.

2. VERİ MÜHENDİSLİĞİ VE ÖN İŞLEME (DATA ENGINEERING)

Veri Kaynağı ve Sayım Dökümü

Projede Kaggle platformu üzerinde sunulan resmi edge-forest-fire-challenge-2025 veri seti modüle edilmiştir.

- Toplam Görüntü Sayısı:** 4.350 adet benzersiz hava/uydu fotoğrafı
- Sağlıklı Orman Sınıfı (nofire):** 2.410 adet görüntü
- Yangın/Duman Sınıfı (fire):** 1.940 adet görüntü

Veri Yükleme ve Pipeline Mimarisi

İşletim sistemi tabanlı dosya yolu (/ veya \) çakışmalarını ve platform bağımlılıklarını tamamen ortadan kaldırmak amacıyla Python pathlib.Path kütüphanesi kullanılmıştır. Veri hattı (Pipeline), PyTorch'un en optimize veri yönetim mimarilerinden biri olan torchvision.datasets.ImageFolder ve DataLoader ile kurulmuştur.

- Otomatik Etiketleme:** Klasör hiyerarşisi üzerinden sıfır manuel iş gücüyle etiket matrisi üretilmiştir.
- G/Ç Optimizasyonu:** pin_memory=True ve num_workers=2 parametreleri set edilerek, verilerin GPU belleğine (VRAM) transferi sırasındaki darboğazlar (I/O bottlenecks) önlenmiştir.

Görsel Ön İşleme ve Veri Artırma (Data Augmentation)

Modelin derin öznelikleri (deep features) doğru öğrenebilmesi ve ezberlemeyi engellemek adına şu transforms.Compose hattı uygulanmıştır:

- 1. Yeniden Boyutlandırma:** Görüntüler 224 x 224 piksel çözünürlüğe sabitlenmiştir.
- 2. Normalizasyon:** ImageNet ön eğitim standartlarına sadık kalınarak pikseller normalize edilmiştir. (mean=[0.485, 0.456, 0.406], std=[0.229, 0.224, 0.225])
- 3. Yatay Simetri:** Modelin değişken duman yönlerini ve farklı kamera açılarını kavrayabilmesi için RandomHorizontalFlip() algoritmasıyla veri seti dinamik olarak çeşitlendirilmiştir.

3. MODEL MİMARİSİ VE DERİN ÖĞRENME MOTORU

Model Seçimi: EfficientNet-B0

Gömülü sistemlerin (Edge AI) kısıtlı bellek ve işlemci (CPU/GPU) kaynakları göz önünde bulundurularak, transfer öğrenme (Transfer Learning) model omurgası olarak EfficientNet-B0 (models.efficientnet_b0) seçilmiştir. Matematiksel bileşik ölçekleme (Compound Scaling) kullanan bu mimari; düşük parametre sayısına rağmen yüksek doğruluk sunması yönüyle dron ve uydu donanımları için idealdir.

Katman Modifikasyonu ve Çıkış Öürümü

Modelin ImageNet'ten gelen 1000 sınıflı doğrusal katmanı (classifier[1]) projenin ikili (Binary) sınıflandırma ihtiyacına göre kesilmiş ve yerine 2 çıkış neronuna sahip doğrusal katman eklenmiştir:

```
model.classifier[1] = nn.Linear(num_features, 2)
```

- Hedef Sınıflar:** 0 -> nofire (Güvenli Bölge)
- Hedef Sınıflar:** 1 -> fire (Aktif Yangın/Duman)

Hiperparametre Seti

- Kayıp Fonksiyonu (Loss):** CrossEntropyLoss (Sınıf olasılık dağılımlarını ölçmek için)
- Optimizasyon Algoritması:** AdamW (Ağırlık sönümlmeli gradyan sabitleyici)
- Öğrenme Oranı (Learning Rate):** 1e-4
- Paket Boyutu (Batch Size):** 32

4. EĞİTİM VE DOĞRULAMA PERFORMANSI (PERFORMANCE ANALYSIS)

Eğitimin her bir döneminde (Epoch) 5 adımlı PyTorch mekaniği tıkr tıkr çalıştırılmıştır:

zero_grad() -> Forward (Tahmin) -> Loss Hesaplama -> Backward (Geriye Yayılım) -> Step (Vida Sıkma)

Dönem (Epoch)	Ortalama Kayıp (Loss)	Eğitim Doğruluğu (Train Acc)
Epoch 1	0.1746	%99.62
Epoch 2	0.0411	%99.72
Epoch 3	0.0164	%99.84

✓Görünmeyen Veri Testi (Validation)

Eğitim sürecinde modelin ağırlık matrisini güncellerken hiç kullanmadığı 'Doğrulama Seti' ile yapılan kalite kontrol sonuçları:

- **Doğrulama Başarı Oranı (Validation Accuracy):** %97.40
- **Doğrulama Kayıp Değeri (Validation Loss):** 0.2160

Mühendislik Değerlendirmesi: Eğitim skoru (%99.84) ile test skoru (%97.40) arasındaki farkın minimal kalması, modelin veri setini ezberlemediğini (Overfitting yapmadığını) ve gerçek saha koşullarında yüksek kararlılıkla çalışacağını doğrulamaktadır.

5. COĞRAFİ BİLGİ SİSTEMLERİ (GIS) ENTEGRASYONU

Canlı Veri Akışı ve Simülasyonu

Projenin makro vizyonunu oluşturan 'Hibrit Sistem' kurgusu için pandas altyapılı bir NASA FIRMS API veri besleme katmanı tasarlanmıştır. Türkiye coğrafi sınırları içerisindeki anlık termal anomaliler (uydulardan gelen yüksek sıcaklık pikselleri) enlem ve boylam bazlı taranarak veri tablosuna indirilmiştir.

Yerelleştirilmiş Matematiksel Dönüşüm

NASA sunucularından gelen ham sıcaklık verileri bilimsel Kelvin (K) standardındadır. Sahadaki operasyonel birimlerin, itfaiye ekiplerinin ve kriz merkezinin veriyi anlık olarak yorumlayabilmesi amacıyla veriler doğrudan Santigrat Dereceye (°C) dönüştürülmüştür:

$$Celsius = Kelvin - 273.15$$

İnteraktif Haritalandırma

Tespit edilen coğrafi odaklar, folium kütüphanesi kullanılarak Türkiye haritası üzerine kırmızı coğrafi işaretçiler (Markers) halinde işlenmiştir. Tarayıcı tabanlı iframe engellerini aşmak amacıyla harita nesnesi saf HTML formatına çevrilmiş ve Kaggle ortamına başarılı bir şekilde render edilmiştir. Harita üzerindeki noktalara tıklandığında anlık koordinat, geçiş saati ve yerel sıcaklık (°C) bilgileri dinamik olarak görüntülenebilmektedir.

6. MODEL DEPOLAMA VE DEPO ALTYAPISI (DEPLOYMENT)

Üretilen yapay zeka beyninin öğrendiği tüm ağırlıklar (Weights), PyTorch standartlarına uygun olarak diske yazılmıştır:

```
torch.save(model.state_dict(), "efficientnet_b0_forest_fire.pt")
```

- **Nihai Dosya Boyutu:** 15.59 MB

Edge AI Değerlendirmesi: 15.59 MB boyutundaki bu mikro ağırlık dosyası, modelin doğruluğundan ödün vermeksizin elde edilmiş bir mühendislik başarısıdır. Bu sayede model; internet kısıtı olan orman kulelerindeki mikrodenetleyicilere, gözlem dronlarına ve gelecekte geliştirilecek mobil uygulamalara harici bir bulut sunucuya ihtiyaç duymadan (Offline/On-Device) gömülebilecek seviyededir.

7. GELECEK VİZYONU VE PROJE YOL HARİTASI

Kaba inşaatı tamamlanan bu proje, gelecekte hayata geçirilecek olan endüstriyel akıllı çevre izleme platformlarının ana motorunu oluşturmaktadır.

- **1. Arayüz Dönüşümü (Streamlit):** Proje, son kullanıcının etkileşime geçebileceği, tarayıcı tabanlı çalışan interaktif bir Web App'e taşınacaktır.
- **2. Sentinel-2 Otomatik API Entegrasyonu:** NASA'dan gelen anlık anomali koordinatı doğrultusunda, o bölgenin güncel Sentinel uydu fotoğrafı internetten otomatik çağrılacak ve bu raporda eğitilen 15.59 MB'lık beyne canlı tahmin için paslanacaktır.
- **3. Hızlandırılmış Donanım Dağıtımı:** Görüntü işleme performansını gerçek zamanlı (Real-time Inference) seviyede tutabilmek için Google Coral Edge TPU donanım optimizasyonları yapılacaktır.